ĐỀ TÀI CUỐI KỲ
MÔN PHÂN TÍCH DỮ LIỆU LỚN TRONG ĐẦU TƯ VÀ KINH DOANH

1. Mục tiêu

- Vận dụng PySpark để xây dựng pipeline xử lý và phân tích dữ liệu có quy mô lớn hoặc có đặc trưng Big Data.
- Thực hiện thu thập/tích hợp dữ liệu, làm sạch, biến đổi, tổng hợp và phân tích dữ liệu nhằm trả lời một bài toán thực tế trong đầu tư hoặc kinh doanh.
- Rút ra insight có ý nghĩa quản trị, kinh doanh hoặc đầu tư; không dừng ở mô tả biểu đồ.
- Xây dựng dashboard trực quan bằng Power BI, Tableau hoặc công cụ BI tương đương.
- Xây dựng ứng dụng Streamlit để trình diễn kết quả phân tích, cho phép người dùng tương tác với dữ liệu/kết quả.
- Rèn luyện khả năng trình bày một quy trình phân tích dữ liệu hoàn chỉnh, có thể tái lập và có sản phẩm demo.

2. Hình thức thực hiện

- Nhóm tối đa 4 sinh viên. Phải ghi rõ phân công của từng thành viên.
- Mỗi nhóm chọn một bài toán thuộc lĩnh vực đầu tư hoặc kinh doanh và đặt 3–5 câu hỏi phân tích cụ thể.
- Nếu làm theo nhóm, phạm vi dữ liệu, số chiều phân tích và mức độ hoàn thiện sản phẩm phải tương xứng với số thành viên.
- Kết quả phải hình thành một pipeline thống nhất: Data → PySpark → Analytics → Dashboard → Streamlit → Insight/Recommendation.

3. Chính sách nộp trễ

- ≤ 24 giờ: trừ 10% điểm.
- ≤ 48 giờ: trừ 30% điểm.
- > 48 giờ: không chấp nhận.
- Mỗi sinh viên có 4 ngày miễn trừ nộp muộn (24 giờ/ngày, không chia nhỏ), nếu quy định lớp cho phép.

4. Quy định trung thực học thuật và sử dụng GenAI

- Phải n ộp sản phẩm gốc của nhóm và toàn bộ mã nguồn cần thiết để tái lập kết quả.
- Được phép sử dụng GenAI để hỗ trợ học tập/lập trình, nhưng phải ghi rõ công cụ và phần việc đã được hỗ trợ.
- Code, script, notebook, dashboard template hoặc tài nguyên lấy từ nguồn khác phải được trích dẫn rõ ràng.
- Nhóm phải hiểu và giải thích được code, pipeline, metric, dashboard và insight do mình nộp.

5. Yêu cầu về dữ liệu

Dữ liệu phải liên quan trực tiếp đến bài toán đầu tư hoặc kinh doanh và đáp ứng ít nhất một trong các điều kiện sau:

- Có quy mô đủ lớn để việc xử lý bằng Spark có ý nghĩa (khuyến nghị từ 100.000 dòng trở lên); hoặc
- Gồm nhiều file/nhiều nguồn dữ liệu cần tích hợp (CSV/JSON/Parquet/API/database); hoặc
- Có dữ liệu theo thời gian/tần suất cao (giao dịch, clickstream, log, giá sản phẩm, dữ liệu thị trường...); hoặc

- Có thể mở rộng quy mô dữ liệu bằng cách kết hợp nhiều kỳ, nhiều mã chứng khoán, nhiều chi nhánh, nhiều sản phẩm... và nhóm giải thích được lý do sử dụng Spark.
- Nguồn dữ liệu phải rõ ràng, có khả năng kiểm chứng. Không khuyến khích dataset quá nhỏ chỉ dùng để minh họa thao tác Spark.

6. Nhóm đề tài và nguồn dữ liệu gợi ý

Nhóm đề tài	Gợi ý nội dung phân tích
Phân tích bán hàng đa kênh	Doanh thu, sản phẩm, khách hàng, khu vực, khuyến mãi; phân tích xu hướng và hiệu quả kinh doanh.
Phân tích hành vi khách hàng	RFM, phân khúc khách hàng, churn, hành vi mua lặp lại, customer lifetime value.
Phân tích thương mại điện tử	Orders, sessions, clickstream, reviews, conversion funnel, sản phẩm bán kèm.
Phân tích giá và khuyến mãi	Theo dõi biến động giá, hiệu quả promotion, price elasticity, so sánh đối thủ.
Phân tích chuỗi cung ứng và tồn kho	Tồn kho, lead time, stock-out, fulfillment, hiệu quả nhà cung cấp.
Phân tích thị trường chứng khoán	Nhiều mã cổ phiếu/ETF, giá–khối lượng, technical indicators, risk/return, correlation.
Phân tích danh mục đầu tư	Lợi suất, volatility, drawdown, diversification, risk-adjusted performance.
Phân tích dữ liệu tài chính doanh nghiệp	Báo cáo tài chính nhiều doanh nghiệp/nhiều kỳ, tăng trưởng, biên lợi nhuận, đòn bẩy.
Phân tích startup và đầu tư mạo hiểm	Funding rounds, industries, locations, investors, exits/acquisitions.
Phân tích phản hồi/đánh giá khách hàng	Reviews/complaints, sentiment/topic, xu hướng vấn đề theo sản phẩm hoặc thời gian.

7. Yêu cầu kỹ thuật bắt buộc

A. PySpark – xử lý và phân tích dữ liệu: Bắt buộc sử dụng PySpark. Tối thiểu phải có: đọc dữ liệu; kiểm tra schema/chất lượng; xử lý missing/duplicate/outlier khi phù hợp; biến đổi dữ liệu; filter; groupBy/aggregation; join giữa các bảng hoặc nguồn; xử lý thời gian; và lưu kết quả phân tích ra Parquet/CSV hoặc bảng trung gian.

B. Phân tích dữ liệu và insight: Thực hiện EDA và các phân tích phục vụ câu hỏi kinh doanh/đầu tư. Có thể dùng Spark SQL, window functions, ranking, cohort, RFM, time-series aggregation, KPI, correlation hoặc kỹ thuật phù hợp khác. Machine Learning là tùy chọn nếu có giá trị cho bài toán.

C. Dashboard BI: Xây dựng dashboard bằng Power BI, Tableau hoặc công cụ BI tương đương. Dashboard phải có KPI chính, bộ lọc, ít nhất 3–5 visual có liên kết logic và hỗ trợ trả lời câu hỏi kinh doanh/đầu tư.

D. Ứng dụng Streamlit: Xây dựng ứng dụng Streamlit để hiển thị kết quả phân tích. Tối thiểu có: trang tổng quan, bộ lọc/điều khiển tương tác, biểu đồ/bảng kết quả và phần diễn giải insight. Streamlit có thể đọc dữ liệu đầu ra từ pipeline PySpark thay vì chạy Spark trực tiếp khi demo.

E. Kiến trúc và khả năng tái lập: Có sơ đồ pipeline dữ liệu; cấu trúc thư mục rõ ràng; requirements.txt/environment; README hướng dẫn chạy; code có chú thích; đường dẫn dữ liệu cấu hình hợp lý.

8. Quy trình thực hiện đề tài

1. Xác định bài toán và câu hỏi phân tích/KPI cần trả lời.
2. Thu thập dữ liệu và mô tả nguồn, schema, kích thước, thời gian, mức độ tin cậy.
3. Dùng PySpark xây dựng pipeline tiền xử lý, tích hợp và tạo bảng phân tích.
4. Thực hiện EDA và phân tích chuyên sâu để trả lời các câu hỏi đã đặt ra.
5. Xuất các bảng/KPI đã xử lý để phục vụ lớp trực quan hóa.
6. Xây dựng dashboard trên Power BI/Tableau (hoặc BI tool tương đương).
7. Xây dựng Streamlit app để trình diễn kết quả phân tích và tương tác.

8. Tổng hợp insight, khuyến nghị, hạn chế và hướng mở rộng.

9. Cấu trúc báo cáo

Chương 1. Tổng quan bài toán: bối cảnh, mục tiêu, câu hỏi phân tích, giá trị kinh doanh/đầu tư.
Chương 2. Dữ liệu và công nghệ: nguồn dữ liệu, đặc trưng Big Data, PySpark, BI tool, Streamlit và kiến trúc pipeline.
Chương 3. Xử lý dữ liệu với PySpark: schema, data quality, cleaning, transformation, join, aggregation, feature/KPI construction.
Chương 4. Phân tích và kết quả: EDA, phân tích theo câu hỏi, insight, bảng/biểu đồ chính.
Chương 5. Dashboard và ứng dụng Streamlit: thiết kế, chức năng, ảnh chụp và hướng dẫn sử dụng.
Chương 6. Kết luận: trả lời câu hỏi, khuyến nghị, hạn chế và hướng phát triển.
Phụ lục: phân công thành viên, mô tả file, hướng dẫn chạy, link repo/demo (nếu có).

10. Sản phẩm phải nộp

- Báo cáo PDF.
- Slide thuyết trình.
- Mã nguồn PySpark/Jupyter Notebook hoặc Python scripts.
- File Power BI (.pbix), Tableau (.twb/.twbx) hoặc file/dashboard tương đương.
- Mã nguồn ứng dụng Streamlit và requirements.txt.
- Dataset mẫu hoặc hướng dẫn tải dữ liệu; không bắt buộc nộp toàn bộ dữ liệu nếu dung lượng quá lớn.
- README hướng dẫn chạy project và mô tả cấu trúc thư mục.
- Tất cả nén lại, ghi rõ Nhom???_DeTaiCK_HoTen_MaSV (nhóm trưởng nộp).

11. Rubric đánh giá (100 điểm)

Tiêu chí	Mô tả yêu cầu	Điểm tối đa	Ghi chú
1. Bài toán & dữ liệu	Bài toán phù hợp đầu tư/kinh doanh; nguồn dữ liệu rõ ràng; mô tả quy mô/schema; câu hỏi/KPI cụ thể; giải thích được lý do dùng Spark.	10 điểm	Bắt buộc
2. Pipeline PySpark	Đọc/tích hợp dữ liệu; xử lý chất lượng dữ liệu; transformation; join; aggregation; Spark SQL/window khi phù hợp; pipeline rõ ràng và chạy được.	25 điểm	Bắt buộc
3. Phân tích & insight	EDA đúng; phân tích nhiều chiều; trả lời câu hỏi đã đặt; insight có ý nghĩa; có diễn giải và khuyến nghị dựa trên dữ liệu.	20 điểm	Bắt buộc
4. Dashboard BI	Power BI/Tableau/BI tool: bố cục rõ, KPI hợp lý, filter/slicer, visual đúng loại, có tính tương tác và hỗ trợ ra quyết định.	15 điểm	Bắt buộc
5. Ứng dụng Streamlit	App chạy được; có filter/interaction; hiển thị KPI, bảng/biểu đồ và insight; giao diện dễ sử dụng; kết nối hợp lý với output pipeline.	15 điểm	Bắt buộc
6. Báo cáo & thuyết trình	Báo cáo logic, hình/bảng rõ; trình bày đúng thời gian; demo được sản phẩm; trả lời câu hỏi và giải thích được lựa chọn kỹ thuật.	10 điểm	Bắt buộc
7. Tái lập & sáng tạo	README, requirements, cấu trúc code tốt; có kiến trúc pipeline; điểm cộng cho ML/forecasting/streaming/cloud/deployment hoặc phân tích đặc sắc.	5 điểm	Có phần nâng cao

12. Mức yêu cầu tối thiểu để được xem là hoàn thành đề tài

- Có pipeline PySpark thực sự được sử dụng để xử lý/phân tích dữ liệu, không chỉ cài đặt hoặc đọc file bằng Spark rồi chuyển toàn bộ sang Pandas.
- Có ít nhất một dashboard Power BI/Tableau (hoặc tương đương) có tính tương tác.
- Có ứng dụng Streamlit chạy được và trình bày ít nhất các KPI/kết quả phân tích chính.
- Có insight và kết luận gắn với bài toán đầu tư/kinh doanh.
- Nhóm demo được toàn bộ luồng dữ liệu và giải thích được vai trò của từng công nghệ.

---o0o---

(Hết)